UniEVANGÉLICA
UNIVERSIDADE EVANGÉLICA DE GOIÁS

GUIA DIDÁTICO

Dataset SIMPA

Como entender, importar e analisar a base de predição de evasão acadêmica

Engenharia de Software | 120 alunos | 8 períodos | 40 disciplinas

Material de apoio para estudantes em início de carreira em Inteligência Artificial

Base integralmente sintética - versão 2026-2

Como usar este guia

Este material foi escrito para quem está começando a trabalhar com bancos de dados e modelos preditivos. A proposta é mostrar não apenas o que existe em cada arquivo, mas por que os dados foram separados dessa forma e como eles se conectam.

> **Ideia central:** Em uma base normalizada, a informação aparece uma vez e é reutilizada por meio de identificadores. Isso reduz repetição, erros e conflitos.

Objetivos de aprendizagem

1. Reconhecer uma chave primária e uma chave estrangeira.
2. Entender a granularidade de uma tabela: o que exatamente representa uma linha.
3. Importar os CSVs na ordem correta em um SGBD.
4. Construir consultas com JOIN para reunir informações relacionadas.
5. Preparar atributos e variável-alvo para um modelo de evasão sem vazamento de informação.

Sugestão de percurso

6. Leia primeiro os conceitos fundamentais e observe o mapa geral.
7. Consulte a explicação do arquivo que estiver usando.
8. Siga a ordem de importação antes de executar as consultas SQL.
9. Somente depois avance para a visão analítica e os experimentos de IA.

Conteúdo do documento

Parte	Assunto
1	Visão geral e organização do pacote
2	Conceitos essenciais de banco de dados
3	Diagramas de relacionamentos
4	Explicação dos 15 CSVs normalizados
5	Arquivos auxiliares
6	Importação e consultas
7	Uso em inteligência artificial
8	Exercícios e glossário

1. Visão geral e organização do pacote

O pacote foi construído com duas formas de acesso. A pasta csv_normalizados contém a versão adequada para um banco relacional. O arquivo simpa_visao_analitica.csv contém uma versão pronta para exploração, com uma linha por aluno.

```
simpa_dataset_2026_2/
|-- csv_normalizados/        15 tabelas relacionais
|-- simpa_visao_analitica.csv
|-- dicionario_dados.csv
|-- schema_sqlite.sql
|-- consultas_exemplo.sql
|-- LEIA-ME.md
|-- RELATORIO_VALIDACAO.md
|-- resumo_validacao.json
`-- simpa_dataset_completo.xlsx
```

Forma	Quando usar	Vantagem	Cuidado
CSVs normalizados	Banco de dados, API e JOINs	Evita repetição e preserva relações	Exige importar várias tabelas
Visão analítica	Gráficos e primeiro experimento de ML	Uma linha por aluno	Repete dados e contém indicadores derivados
Workbook XLSX	Consulta humana e aula expositiva	Abas organizadas e formatação	Não substitui um SGBD

> **Dado sintético:** Nenhum nome, endereço, nota ou desfecho corresponde a uma pessoa real. Mesmo assim, a turma deve praticar princípios de minimização, controle de acesso e LGPD.

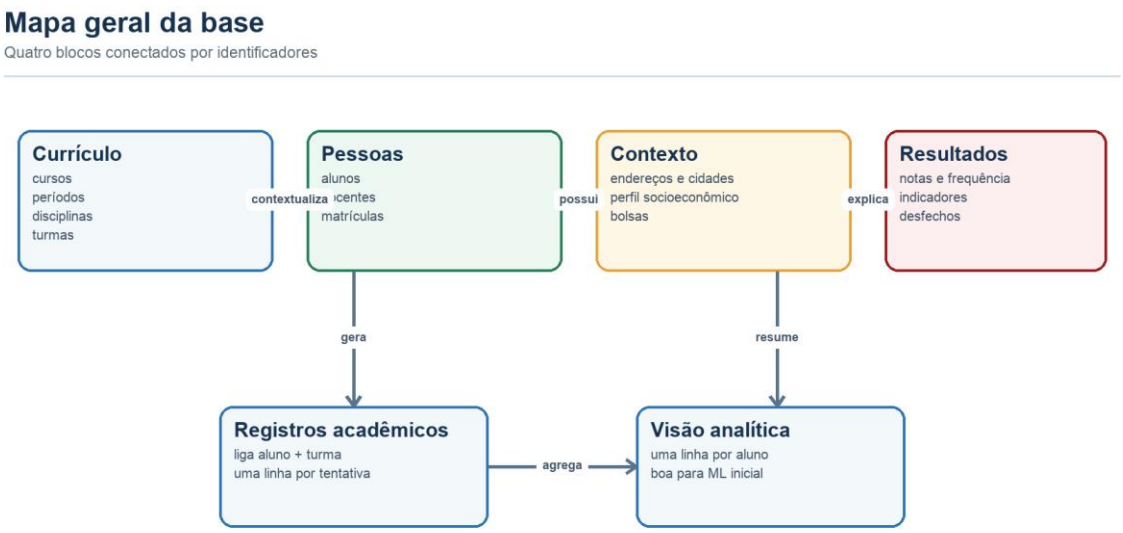


Figura 1 - Mapa geral dos blocos de informação

2. Conceitos essenciais de banco de dados

Antes de abrir os arquivos, vale dominar seis ideias. Elas aparecem repetidamente em todo o dataset.

Conceito	Significado simples	Exemplo no SIMPA
Tabela	Conjunto de linhas sobre o mesmo tipo de coisa.	alunos.csv contém somente alunos.
Linha	Uma ocorrência do tipo representado pela tabela.	Uma linha de turmas.csv representa uma oferta.
Coluna	Uma característica armazenada para todas as linhas.	turno, nota_final ou cidade_id.
Chave primária (PK)	Identificador único de cada linha.	aluno_id não se repete em alunos.csv.
Chave estrangeira (FK)	Campo que aponta para a PK de outra tabela.	enderecos_alunos.cidade_id aponta para cidades.
Granularidade	O que uma linha representa exatamente.	Um registro acadêmico = aluno + turma + tentativa.
NULL	Valor ausente, desconhecido ou ainda não aplicável.	nota_final fica vazia quando a disciplina está em curso.
JOIN	Operação que reúne tabelas usando chaves relacionadas.	Juntar alunos, endereços e cidades.

> **Pergunta-guia:** Antes de analisar qualquer tabela, pergunte: o que representa uma linha e qual campo identifica essa linha sem ambiguidade?

Por que normalizar?

Imagine repetir o texto 'Anápolis - GO' em milhares de registros acadêmicos. Uma correção de grafia exigiria alterar muitas linhas. Na versão normalizada, a cidade é cadastrada uma vez e os demais arquivos guardam apenas cidade_id.

Problema evitado	Como a estrutura resolve
Duplicação	Cadastros como cidades, disciplinas e docentes ficam em tabelas próprias.
Atualização inconsistente	Uma alteração é feita no registro central, não em centenas de cópias.
Exclusão acidental	As chaves estrangeiras ajudam a impedir referências órfãs.
Dificuldade de auditoria	Cada tabela tem função e granularidade documentadas.

3. Diagramas dos relacionamentos

Nos diagramas, 1:N significa que uma linha do lado 1 pode se relacionar com várias linhas do lado N.

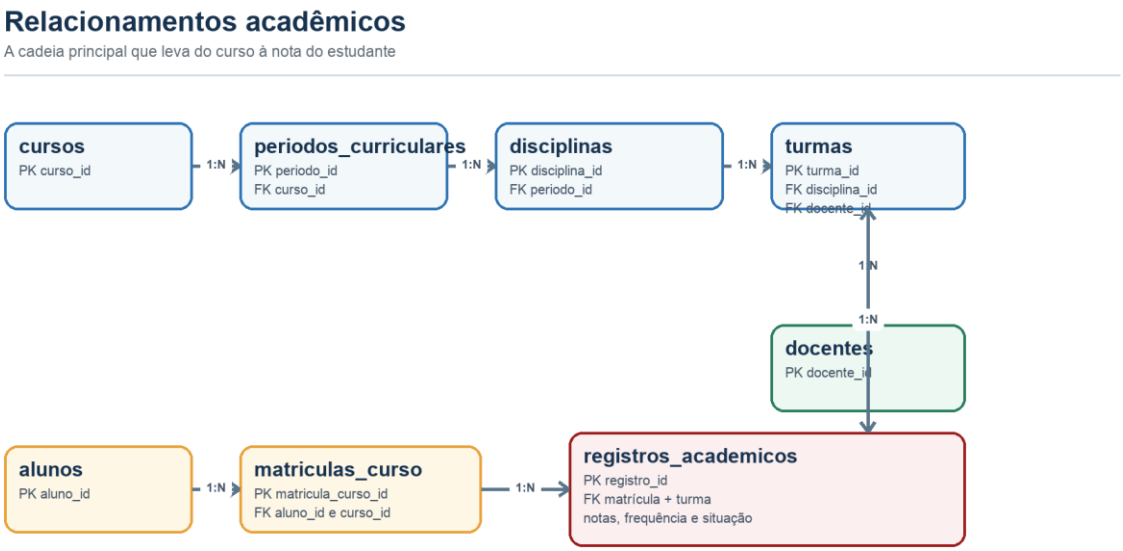


Figura 2 - Cadeia acadêmica principal

> **Leitura da cadeia:** Para descobrir a disciplina de uma nota, parta de registros_academicos, siga turma_id até turmas e depois disciplina_id até disciplinas.

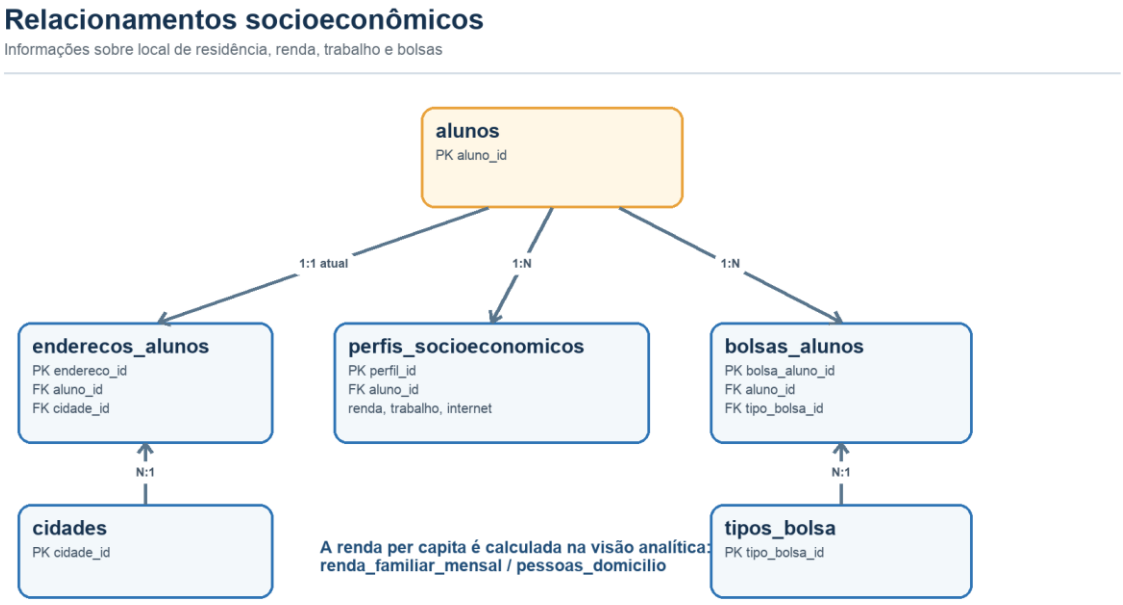


Figura 3 - Endereço, perfil socioeconômico e bolsas

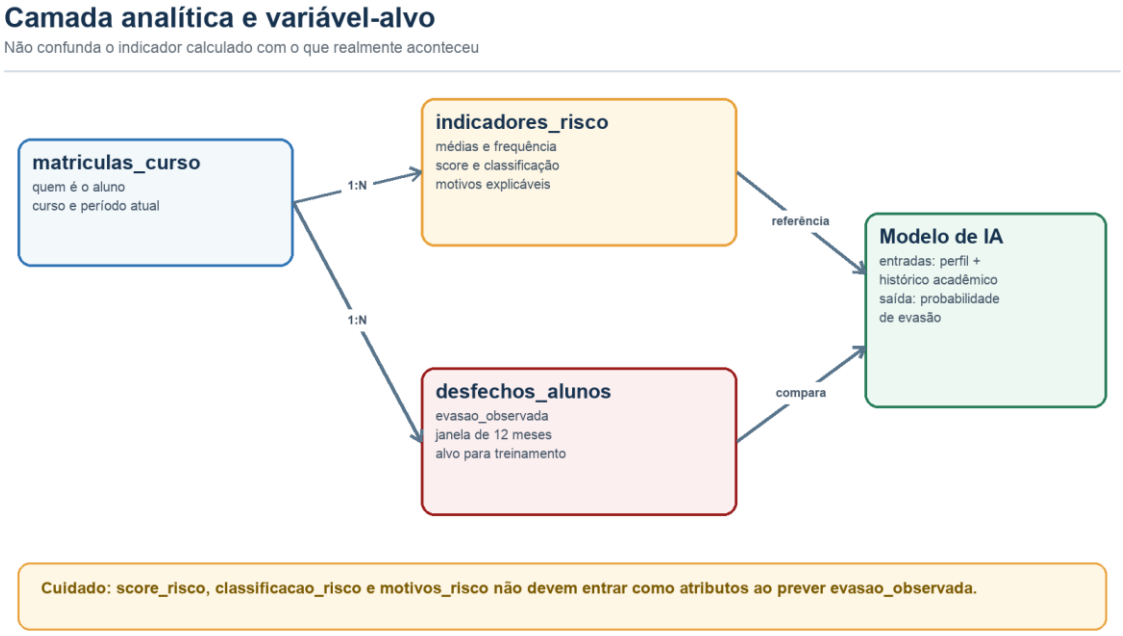


Figura 4 - Indicadores calculados e desfecho observado

4. Os 15 CSVs normalizados

As próximas seções seguem a ordem lógica do domínio. Em cada arquivo, observe a granularidade, a chave primária e as chaves estrangeiras. Esses três elementos dizem como a tabela deve ser usada.

4.1 Estrutura curricular e oferta

Este grupo responde onde, quando e por quem cada disciplina é ofertada.

cursos.csv

Descreve o curso oferecido pela instituição. É o ponto de partida da estrutura curricular.

Aspecto	Explicação
Quantidade de linhas	1
Granularidade	Uma linha por curso.
Chave primária	curso_id
Chaves estrangeiras	Nenhuma.

Perguntas que este arquivo ajuda a responder:

10. Qual é o curso analisado?
11. Quantos períodos ele possui?
12. Qual é sua modalidade e cidade-sede?

Campos essenciais

Campo	Significado	Exemplo
curso_id	Identificador interno do curso.	1
total_periodos	Quantidade de períodos previstos.	8
disciplinas_por_periodo	Campo de resumo que requer validação: nesta versão registra 40, mas a estrutura curricular possui 5 disciplinas por período.	40
cidade_sede	Cidade usada como referência de deslocamento.	Anápolis

periodos_curriculares.csv

Divide o curso em oito etapas curriculares e registra a carga horária planejada de cada uma.

Aspecto	Explicação
Quantidade de linhas	8
Granularidade	Uma linha por período de um curso.
Chave primária	periodo_id
Chaves estrangeiras	curso_id -> cursos.csv

Perguntas que este arquivo ajuda a responder:

13. Quantas disciplinas há no 3º período?
14. Qual é a carga horária prevista do 7º período?

Campos essenciais

Campo	Significado	Exemplo
periodo_id	Identificador do período.	1
curso_id	Curso ao qual o período pertence.	1
numero_periodo	Número de 1 a 8.	1
quantidade_disciplinas	Sempre 5 nesta base.	5

disciplinas.csv

É o catálogo das 40 disciplinas do curso. Cada disciplina aponta para seu período recomendado.

Aspecto	Explicação
Quantidade de linhas	40
Granularidade	Uma linha por disciplina curricular.
Chave primária	disciplina_id
Chaves estrangeiras	periodo_id -> periodos_curriculares.csv

Perguntas que este arquivo ajuda a responder:

15. Quais disciplinas formam o 2º período?
16. Qual disciplina possui maior carga horária?
17. Quais são projetos integradores?

Campos essenciais

Campo	Significado	Exemplo
codigo	Código curto e único da disciplina.	ES0101
periodo_id	Período curricular recomendado.	1
carga_horaria	Horas planejadas.	80
indice_dificuldade_sintetico	Parâmetro da simulação; não é medida real.	0.23

docentes.csv

Mantém os docentes separados das turmas, evitando repetir nome, titulação e regime a cada oferta.

Aspecto	Explicação
Quantidade de linhas	18
Granularidade	Uma linha por docente sintético.
Chave primária	docente_id
Chaves estrangeiras	Nenhuma.

Perguntas que este arquivo ajuda a responder:

18. Quais turmas pertencem ao mesmo docente?
19. Qual é a distribuição de titulação?

Campos essenciais

Campo	Significado	Exemplo
docente_id	Identificador do docente.	1
nome_sintetico	Rótulo fictício.	Docente Ada
titulacao	Especialista, mestre ou doutor.	Mestre
regime_trabalho	Tempo integral ou parcial.	Tempo integral

turmas.csv

Representa cada oferta de uma disciplina em determinado semestre, com docente, turno e modalidade.

Aspecto	Explicação
Quantidade de linhas	320
Granularidade	Uma linha por oferta de disciplina e semestre.
Chave primária	turma_id
Chaves estrangeiras	disciplina_id -> disciplinas.csv; docente_id -> docentes.csv

Perguntas que este arquivo ajuda a responder:

20. Em qual semestre a turma foi ofertada?
21. Quem ministrou a turma?
22. Qual era o turno e a modalidade?

Campos essenciais

Campo	Significado	Exemplo
turma_id	Identificador da oferta.	1
codigo_turma	Código único legível.	ES0101-2023.1-A
ano_letivo / semestre_letivo	Momento da oferta.	2023 / 1
vagas	Capacidade planejada.	45

4.2 Alunos e contexto socioeconômico

Este grupo descreve quem é o estudante e quais condições podem contextualizar sua experiência acadêmica.

alunos.csv

É o cadastro central dos 120 estudantes. Os nomes e códigos são inteiramente sintéticos.

Aspecto	Explicação
Quantidade de linhas	120
Granularidade	Uma linha por aluno.
Chave primária	aluno_id
Chaves estrangeiras	Nenhuma.

Perguntas que este arquivo ajuda a responder:

23. Qual código acadêmico identifica o aluno?
24. Qual é a faixa etária da amostra?

Campos essenciais

Campo	Significado	Exemplo
aluno_id	Chave técnica usada nos relacionamentos.	1
codigo_academico	Código fictício mais amigável.	AES0001
nome_sintetico	Não representa pessoa real.	Estudante Sintético 001
origem_dado	Marca explicitamente o caráter sintético.	SINTETICO

cidades.csv

Lista as cidades de residência possíveis e a distância aproximada até Anápolis.

Aspecto	Explicação
Quantidade de linhas	15
Granularidade	Uma linha por cidade e UF.
Chave primária	cidade_id
Chaves estrangeiras	Nenhuma.

Perguntas que este arquivo ajuda a responder:

25. Quantos alunos vêm de fora de Anápolis?
26. A distância está associada ao tempo de deslocamento?

Campos essenciais

Campo	Significado	Exemplo
cidade_id	Identificador da cidade.	1
nome / uf	Localidade.	Anápolis / GO
distancia_rodoviaria_aprox_km	Valor aproximado usado na simulação.	0

enderecos_alunos.csv

Guarda o endereço fictício e o tempo estimado de deslocamento sem poluir o cadastro principal do aluno.

Aspecto	Explicação
Quantidade de linhas	120
Granularidade	Uma linha por endereço atual de aluno.
Chave primária	endereco_id
Chaves estrangeiras	aluno_id -> alunos.csv; cidade_id -> cidades.csv

Perguntas que este arquivo ajuda a responder:

27. Em qual cidade o aluno reside?
28. Quanto tempo ele leva até a universidade?

Campos essenciais

Campo	Significado	Exemplo
aluno_id	Liga o endereço ao estudante.	1
cidade_id	Evita repetir cidade e UF.	2
logradouro_sintetico	Endereço fictício.	Rua das Araras
tempo_deslocamento_min	Variável útil para análise de risco.	78

perfis_socioeconomicos.csv

Registra um retrato temporal de renda, trabalho, composição domiciliar, internet e origem escolar.

Aspecto	Explicação
Quantidade de linhas	120
Granularidade	Uma linha por aluno e data de referência.
Chave primária	perfil_id
Chaves estrangeiras	aluno_id -> alunos.csv

Perguntas que este arquivo ajuda a responder:

29. O aluno trabalha?
30. Qual é a renda familiar?
31. A internet é estável?
32. Ele é a primeira geração da família no ensino superior?

Campos essenciais

Campo	Significado	Exemplo
data_referencia	Permite manter novos retratos no futuro.	2026-08-01
renda_familiar_mensal	Renda total do domicílio.	6460.65
pessoas_domicilio	Usado para calcular renda per capita.	2
horas_trabalho_semana	Carga semanal de trabalho.	40
qualidade_internet	INSTAVEL, REGULAR ou BOA.	BOA

tipos_bolsa.csv

É o catálogo dos tipos de bolsa ou financiamento. Separa a definição do benefício de sua concessão ao aluno.

Aspecto	Explicação
Quantidade de linhas	4
Granularidade	Uma linha por tipo de benefício.
Chave primária	tipo_bolsa_id
Chaves estrangeiras	Nenhuma.

Perguntas que este arquivo ajuda a responder:

33. Quais benefícios existem?
34. Qual percentual cada tipo cobre?

Campos essenciais

Campo	Significado	Exemplo
tipo_bolsa_id	Identificador do tipo.	1
nome	Nome do benefício.	Bolsa social integral
categoria	Social, mérito ou financiamento.	SOCIAL
percentual	Percentual sintético do benefício.	100

bolsas_alunos.csv

Registra a concessão de um tipo de bolsa a um aluno, incluindo vigência e situação.

Aspecto	Explicação
Quantidade de linhas	53
Granularidade	Uma linha por concessão de bolsa ao aluno.
Chave primária	bolsa_aluno_id
Chaves estrangeiras	aluno_id -> alunos.csv; tipo_bolsa_id -> tipos_bolsa.csv

Perguntas que este arquivo ajuda a responder:

35. Quem é bolsista?
36. Qual tipo de bolsa possui?
37. A concessão ainda está ativa?

Campos essenciais

Campo	Significado	Exemplo
aluno_id	Beneficiário.	3
tipo_bolsa_id	Benefício concedido.	2
data_inicio / data_fim	Vigência.	2026-08-01 / NULL
status	Situação atual da concessão.	ATIVA

matriculas_curso.csv

Liga o aluno ao curso e guarda o contexto acadêmico atual: ingresso, período, turno e status.

Aspecto	Explicação
Quantidade de linhas	120
Granularidade	Uma linha por matrícula de aluno em curso.
Chave primária	matricula_curso_id
Chaves estrangeiras	aluno_id -> alunos.csv; curso_id -> cursos.csv

Perguntas que este arquivo ajuda a responder:

38. Em que ano o aluno ingressou?
39. Qual é seu período atual?
40. Qual foi a forma de ingresso?

Campos essenciais

Campo	Significado	Exemplo
matricula_curso_id	Chave usada pelos registros acadêmicos.	1
periodo_atual	Estágio atual, de 1 a 8.	1
status	ATIVO na data de referência.	ATIVO
forma_ingresso	Vestibular, ENEM, transferência ou segunda graduação.	ENEM

4.3 Histórico acadêmico, risco e desfecho

Este grupo concentra os fatos medidos e as variáveis necessárias para análise e predição.

registros_academicos.csv

É a tabela de fatos acadêmicos. Conecta a matrícula do aluno à turma e registra notas, frequência, situação e tentativas.

Aspecto	Explicação
Quantidade de linhas	2.949
Granularidade	Uma linha por matrícula de curso, turma e tentativa.
Chave primária	registro_id
Chaves estrangeiras	matricula_curso_id -> matriculas_curso.csv; turma_id -> turmas.csv

Perguntas que este arquivo ajuda a responder:

41. Qual foi a nota final do aluno?
42. Ele reprovou por nota ou frequência?
43. Quantas tentativas realizou?
44. Como seu desempenho evoluiu?

Campos essenciais

Campo	Significado	Exemplo
tentativa	1 na primeira matrícula; 2 quando há repetição.	1
situacao	APROVADO, REPROVADO_* ou EM_CURSO.	EM_CURSO
nota_n1 / nota_n2 / nota_projeto	Componentes da avaliação.	98.9 / 87.1 / NULL
nota_final	Nula quando a disciplina está em curso.	NULL
frequencia_percentual	Percentual de presença; alguns nulos são intencionais.	100

indicadores_risco.csv

Materializa medidas calculadas por matrícula: médias, tendência, reprovações e uma heurística explicável de risco.

Aspecto	Explicação
Quantidade de linhas	120
Granularidade	Uma linha por matrícula e data de referência.
Chave primária	indicador_id
Chaves estrangeiras	matricula_curso_id -> matriculas_curso.csv

Perguntas que este arquivo ajuda a responder:

45. Quem apresenta maior risco?
46. Quais evidências sustentam a classificação?
47. A tendência de notas está caindo?

Campos essenciais

Campo	Significado	Exemplo
media_historica	Média das disciplinas finalizadas.	88.9
tendencia_nota_por_periodo	Inclinação linear: positiva melhora, negativa queda.	0
score_risco_percentual	Heurística de 0 a 100.	1.5
motivos_risco	Evidências interpretáveis separadas por |.	alta_carga_de_trabalho

desfechos_alunos.csv

Guarda o resultado observado na janela futura. É a fonte da variável-alvo para experimentos de classificação.

Aspecto	Explicação
Quantidade de linhas	120
Granularidade	Uma linha por matrícula e janela de observação.
Chave primária	desfecho_id
Chaves estrangeiras	matricula_curso_id -> matriculas_curso.csv

Perguntas que este arquivo ajuda a responder:

48. O aluno evadiu nos 12 meses seguintes?
49. Qual era a janela preditiva?
50. Em que data ocorreu o evento ou a censura?

Campos essenciais

Campo	Significado	Exemplo
inicio_janela / fim_janela	Período em que o desfecho é observado.	2026-08-01 / 2027-07-31
evasao_observada	1 para evasão; 0 para permanência.	0
tipo_desfecho	EVASAO ou PERMANENCIA.	PERMANENCIA
data_evento_ou_censura	Data do evento ou fim do acompanhamento.	2027-07-31

> **A tabela mais importante para análises:** registros_academicos.csv é o centro das notas e frequências. Ela não guarda o nome da disciplina nem o nome do aluno: essas informações chegam por JOIN.

5. Arquivos auxiliares

Além dos CSVs normalizados, o pacote inclui arquivos que ajudam a importar, entender, consultar e validar a base.

Arquivo	Para que serve
simpa_visao_analitica.csv	Uma linha por aluno. Junta os principais atributos e o alvo; facilita gráficos e o primeiro modelo, mas não substitui a base normalizada.
dicionario_dados.csv	Explica campo por campo: tabela, tipo sugerido, chave, nulabilidade, descrição e exemplo.
schema_sqlite.sql	Cria as 15 tabelas no SQLite com chaves primárias, estrangeiras e restrições de unicidade.
consultas_exemplo.sql	Contém consultas prontas para risco, desempenho por disciplina, evasão por cidade, bolsas e qualidade dos dados.
LEIA-ME.md	Apresenta o escopo, as convenções, a ordem de importação e os cuidados metodológicos.
RELATORIO_VALIDACAO.md	Resume as verificações de integridade e as relações estatísticas intencionais.
resumo_validacao.json	Versão legível por programas dos principais totais validados.
simpa_dataset_completo.xlsx	Reúne as tabelas em abas formatadas e acrescenta uma folha inicial de orientação.
simpa_dataset_2026_2.zip	Pacote de distribuição que reúne todos os artefatos do dataset.

Como escolher o arquivo certo

Aspecto	Explicação
Quero criar as tabelas rapidamente	Comece por schema_sqlite.sql e depois importe csv_normalizados/.
Quero descobrir o significado de uma coluna	Abra dicionario_dados.csv.
Quero fazer meu primeiro gráfico	Use simpa_visao_analitica.csv.
Quero conferir se minha consulta está correta	Compare com consultas_exemplo.sql.
Quero navegar visualmente	Abra simpa_dataset_completo.xlsx.

> **Importante:** A visão analítica é uma conveniência. A aplicação SIMPA deve preferir as tabelas normalizadas para cadastro, atualização e API.

6. Importação e primeiras consultas

Uma chave estrangeira só pode apontar para uma linha que já existe. Por isso a ordem de importação começa nas tabelas independentes e termina nas tabelas de fatos e resultados.



Figura 5 - Ordem recomendada de importação

Passo a passo com SQLite

51. Crie um banco vazio, por exemplo simpa.db.
52. Execute schema_sqlite.sql para criar as tabelas e ativar as chaves estrangeiras.
53. Importe cada CSV seguindo a ordem da Figura 5.
54. Execute uma contagem simples em cada tabela para conferir as linhas.
55. Só então rode consultas com JOIN e agregações.

> **Resultado esperado:** A importação de teste foi executada sem violações de integridade referencial.

Consulta 1: juntar aluno, endereço e cidade

```
SELECT a.codigo_academico,
       c.nome AS cidade,
       e.tempo_deslocamento_min
FROM alunos a
JOIN enderecos_alunos e ON e.aluno_id = a.aluno_id
JOIN cidades c ON c.cidade_id = e.cidade_id;
```

O primeiro JOIN encontra o endereço do aluno; o segundo converte cidade_id no nome legível da cidade.

Consulta 2: média de nota por disciplina

```
SELECT d.codigo,
       d.nome,
       ROUND(AVG(r.nota_final), 2) AS media_nota
FROM registros academicos r
JOIN turmas t ON t.turma_id = r.turma_id
JOIN disciplinas d ON d.disciplina_id = t.disciplina_id
WHERE r.nota final IS NOT NULL
GROUP BY d.disciplina_id, d.codigo, d.nome
ORDER BY media_nota;
```

O filtro remove as disciplinas ainda em andamento, cuja nota final é NULL.

Consulta 3: alunos com risco mais alto

```
SELECT a.codigo_academico,
       i.score_risco_percentual,
       i.classificacao_risco,
       i.motivos_risco
FROM indicadores_risco i
JOIN matriculas_curso m
  ON m.matricula_curso_id = i.matricula_curso_id
JOIN alunos a ON a.aluno_id = m.aluno_id
ORDER BY i.score_risco_percentual DESC
LIMIT 20;
```

7. Exemplo completo: seguindo um aluno pelas tabelas

O estudante AES0005 é sintético e foi escolhido apenas para demonstrar o caminho dos dados. O objetivo não é avaliar uma pessoa, mas aprender a navegar pelas chaves.

Etapa	O que encontramos
alunos.csv	Localiza aluno_id e o código acadêmico.
matriculas_curso.csv	Mostra o período 1 e o turno Matutino.
enderecos_alunos.csv + cidades.csv	Mostram Aparecida de Goiânia e 111 minutos de deslocamento.
perfis_socioeconomicos.csv	Traz renda familiar de R$ 12.573,56. trabalho e qualidade da internet,
registros_academicos.csv	Contém as notas parciais e a frequência nas turmas.
indicadores_risco.csv	Resume score 39.99 e classe MODERADO.
desfechos_alunos.csv	Registra evasao_observada = 1 na janela futura.

> **Observe:** O código acadêmico aparece na tabela alunos, mas os registros acadêmicos usam matricula_curso_id. Essa separação permite que um aluno tenha outras matrículas no futuro.

Como pensar em um JOIN

Um JOIN não adivinha relações. Ele compara campos compatíveis. Se registros_academicos.matricula_curso_id vale 5, a consulta procura a linha de matriculas_curso cuja chave primária também vale 5.

```
registros_academicos.matricula_curso_id
                |
                +--> matriculas_curso.matricula_curso_id
                                        |
                                        +--> alunos.aluno_id
```

8. Do banco de dados ao modelo de IA

O dataset permite construir um classificador que estime a chance de evasão na janela de 12 meses. A variável-alvo é evasao_observada, disponível em desfechos_alunos.csv.

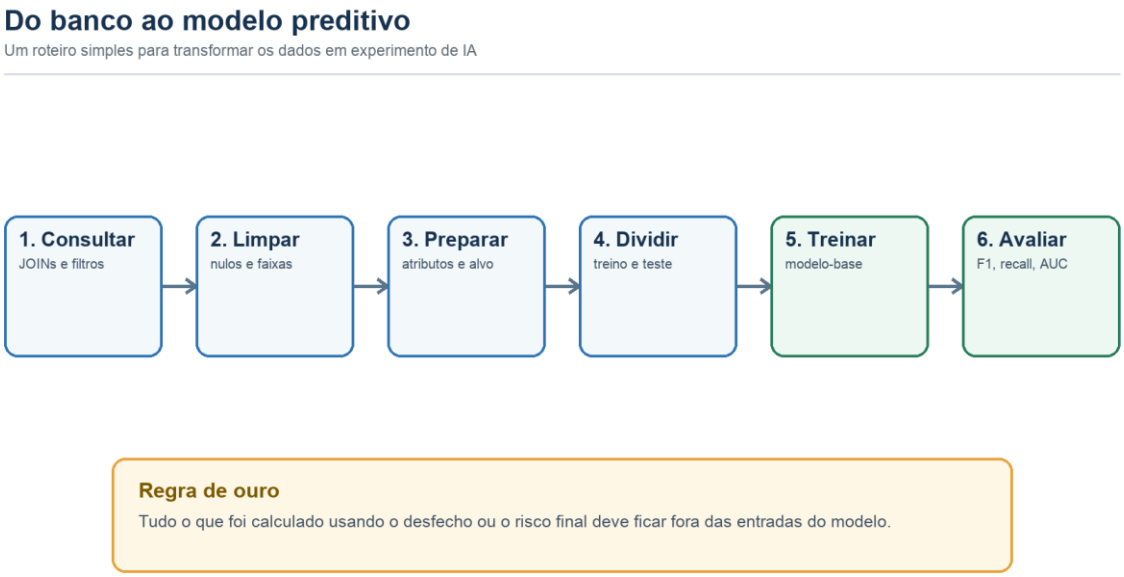


Figura 6 - Pipeline didático de modelagem

Possíveis atributos de entrada

56. média do período atual e média histórica;
57. frequência média e quantidade de reprovações;
58. tendência das notas ao longo dos períodos;
59. tempo de deslocamento e cidade;
60. renda, carga de trabalho, dependentes e qualidade da internet;
61. presença e tipo de bolsa.

Campos que causam vazamento

> **Não use como entrada:** score_risco_percentual, classificacao_risco e motivos_risco foram calculados para resumir o risco. Usá-los para prever evasao_observada faria o modelo aprender uma resposta já parcialmente pronta.

Divisão e avaliação

Prática	Por que importa
Divisão estratificada	Mantém aproximadamente 16,7% de evasões em treino e teste.
Baseline	Compare o modelo com a regra simples de sempre prever permanência.
Recall	Indica quantos alunos que evadiram foram identificados.
Precisão	Indica quantos alertas de risco foram confirmados.
F1	Equilibra precisão e recall.
ROC-AUC	Avalia a ordenação das probabilidades em diferentes limiares.
Matriz de confusão	Mostra acertos e erros por classe de forma concreta.

> **Ética:** O modelo deve apoiar o acolhimento, não punir estudantes. Um alerta representa necessidade de análise humana e possível intervenção, não certeza de evasão.

9. Qualidade dos dados e valores ausentes

O documento norteador do SIMPA pede atenção a valores ausentes, faixas inválidas e padronização. A base inclui ausências controladas para que os alunos pratiquem essas verificações.

Situação	Quantidade	Como interpretar
nota_final nula	600	Correta nas 600 matrículas em andamento.
nota_parcial nula	3	Ausência intencional que exige tratamento.
frequência nula	12	Ausência intencional para auditoria de qualidade.
evasão observada	20 de 120	Classe minoritária: 16,7%.
residentes fora de Anápolis	57 de 120	Permite analisar deslocamento e cidade.
bolsistas/financiados	53 de 120	Permite comparar grupos.
disciplinas_por_periodo	40 no metadado	Inconsistência detectada; a estrutura real tem 5 por período.

Regras simples de validação

62. Notas e frequências devem ficar entre 0 e 100.
63. nota_final pode ser NULL quando situacao = EM_CURSO.
64. Toda turma deve apontar para uma disciplina e um docente existentes.
65. Todo registro acadêmico deve apontar para uma matrícula e uma turma existentes.
66. Datas devem usar o padrão AAAA-MM-DD.
67. Campos vazios no CSV devem ser importados como NULL, não como texto vazio.

> **Não apagar automaticamente:** Um valor ausente pode significar que a informação ainda não foi registrada. Antes de remover linhas, entenda a regra de negócio.

10. Exercícios sugeridos

Os exercícios estão organizados por progressão. O ideal é registrar consultas, gráficos e interpretações no relatório do grupo.

Nível 1 - Exploração

68. Conte alunos por período, cidade e turno.
69. Calcule média, mediana e desvio-padrão das notas finais.
70. Compare frequência média de bolsistas e não bolsistas.
71. Liste disciplinas com maior taxa de reprovação.

Nível 2 - Relacionamentos

72. Crie uma consulta com aluno, cidade, período, média e frequência.
73. Encontre alunos que repetiram uma disciplina e compare as tentativas.
74. Calcule renda per capita sem usar a visão analítica.
75. Construa um dashboard com 3 a 6 indicadores úteis.

Nível 3 - Predição

76. Monte uma base de atributos sem usar os campos de vazamento.
77. Treine uma regressão logística como baseline.
78. Compare com árvore de decisão ou floresta aleatória.
79. Explique falsos positivos e falsos negativos no contexto acadêmico.
80. Crie uma recomendação interpretável para cada perfil de risco.

> **Entrega recomendada:** Para cada análise, inclua a pergunta, a consulta ou código, o resultado e uma interpretação em linguagem simples.

11. Glossário rápido

Termo	Definição
Atributo	Variável usada como entrada de um modelo.
Classe	Categoria que o modelo tenta prever, como evasão ou permanência.
Censura	Fim do acompanhamento sem ocorrência do evento.
Chave estrangeira	Campo que aponta para a chave primária de outra tabela.
Chave primária	Identificador único de uma linha.
Correlação	Medida de associação; não prova causalidade.
Granularidade	Unidade representada por cada linha.
Heurística	Regra explicável construída com critérios e pesos.
JOIN	Operação que combina tabelas relacionadas.
Normalização	Organização que reduz repetição e inconsistência.
NULL	Valor ausente ou não aplicável.
Outlier	Observação muito distante do comportamento mais comum.
Snapshot	Retrato dos dados em uma data de referência.
Variável-alvo	Resultado que o modelo tenta prever.
Vazamento	Uso indevido de informação que entrega parte da resposta ao modelo.

Resumo final

81. Use os CSVs normalizados para banco de dados e API.
82. Use a visão analítica para exploração inicial e protótipos de ML.
83. Sempre identifique a granularidade, a PK e as FKs antes de consultar uma tabela.
84. Trate NULL conforme a regra de negócio.
85. Separe atributos e variável-alvo sem vazamento.
86. Explique o risco e mantenha supervisão humana nas intervenções.

> **Próximo passo:** Crie o banco SQLite, carregue as tabelas e reproduza as três consultas deste guia. Depois, escolha uma pergunta acadêmica e desenvolva sua própria análise.